Dauphine | PSL
UNIVERSITÉ PARIS

ANNEE 2026-2027

Liste des sujets de Mémoire M1 pour la majeure Actuariat

Coordinateur : Tachfine El Alami, F506, elalami@ceremade.dauphine.fr

Liste des sujets

Numéro	Structure	Encadrant principal	Titre
A1	Exiom Partners	Willy MARAIS et Alexandre KEBE	Élaboration d'un produit d'assurance de personne clé appliqué au football professionnel
A2	Université Paris-Dauphine	Mathis RIBORDY	Modélisation de champs de précipitations pour l'évaluation du risque assurantiel via des modèles génératifs
A3	Université Paris-Dauphine	Quentin GUIBERT	Modélisation de la mortalité journalière et modèles additifs
A4	Université Paris-Dauphine	Quentin GUIBERT	Modélisation de la mortalité avec modèles de vitalité
A5	Université Paris-Dauphine	Tachfine EL ALAMI	Prévision de la mortalité en Europe : Lee–Carter, Li–Lee et modèles de fondation
A6	Université Paris-Dauphine	Tachfine EL ALAMI	Prévision des séries financières : ARIMA, XGBoost et modèles hybrides

Sujet A1

Élaboration d'un produit d'assurance de personne clé appliqué au football professionnel

Protection des clubs contre la perte de valeur marchande de leurs joueurs en cas de blessure ou de décès

---

Entreprise : Exiom Partner

Encadrants : Willy MARAIS, Alexandre KEBE

Email : willy.marais@exiompartners.com, alexandre.kebe@exiompartners.com

Nombre d'étudiants / durée :

Le cabinet EXIOM

Le cabinet EXIOM Partners est spécialisé dans les Services Financiers aux entreprises des secteurs de l'assurance et de la banque, et intervient principalement sur les métiers de la Finance, des Risques et de la Conformité auprès de ses clients, tant sur le volet métier que sur le volet IT.

EXIOM Partners a été fondé en 2019 par d'anciens associés issus de grands cabinets généralistes, sur l'idée d'un modèle de management innovant et porteur de valeurs pour ses clients et ses collaborateurs. L'esprit d'équipe, l'engagement, l'indépendance et l'entreprenariat guident la qualité de notre service et le développement de nos talents.

La diversité des expertises et des profils au sein du cabinet nous permet d'intervenir sur de nombreux domaines (par exemple Risk Advisory, finance quantitative, actuariat, transformation métier et organisationnelle), et d'accompagner nos clients confrontés à des exigences réglementaires variées en termes de reporting, de conformité et de gouvernance, ainsi qu'à un environnement technologique innovant (robotisation, Big Data).

Contexte

Dans le football professionnel, un joueur peut représenter à lui seul un investissement de plusieurs dizaines de millions d'euros. Certains transferts dépassent aujourd'hui les 100 millions d'euros. Une blessure grave peut fortement réduire la valeur marchande d'un joueur, voire la rendre nulle en cas d'incapacité définitive ou de décès. Pour un club, perdre un joueur peu après son acquisition signifie donc pouvoir perdre une part importante de son investissement sans avoir eu le temps d'en tirer la valeur sportive ou financière attendue.

Tous les joueurs ne présentent cependant pas le même risque. L'âge, le poste, l'historique de blessures ou encore le temps de jeu peuvent influencer à la fois la probabilité de blessure et ses conséquences sur la valeur marchande. L'enjeu est donc de relier les caractéristiques du joueur au risque financier réellement porté par le club.

Un seul jeu de données public disponible sur Kaggle suffit. Il regroupe dix bases de données sur le monde du football, contenant notamment les caractéristiques des joueurs, leurs blessures, leurs valeurs marchandes, leurs transferts et leurs apparitions. Leur croisement permet de disposer des informations nécessaires pour étudier conjointement le risque de blessure et la perte de valeur marchande.

Problématique

La valeur marchande d'un joueur ne suffit pas à déterminer le risque supporté par le club. Deux joueurs valorisés au même montant peuvent avoir des probabilités de blessure différentes selon leur âge, leur poste ou leurs antécédents. L'impact financier d'une blessure est également variable. Certaines n'affectent que temporairement la valeur du joueur, tandis que d'autres peuvent entraîner une décote durable, voire une perte totale de valeur en cas d'incapacité définitive. Le décès constitue quant à lui un risque distinct entraînant la perte de la valeur marchande du joueur pour le club.

L'enjeu est donc d'estimer le risque propre à chaque joueur ainsi que les conséquences financières d'une blessure ou d'un décès, afin de déterminer la prime d'assurance correspondante.

Comment construire et tarifer un produit d'assurance permettant de protéger les clubs de football professionnel contre la perte de valeur marchande de leurs joueurs à la suite d'une blessure grave ou d'un décès ?

Méthodologie en 4 phases

Le projet suit les différentes étapes nécessaires à la construction du produit d'assurance. Les données permettent d'abord de caractériser le risque propre à chaque joueur. Il faut ensuite estimer la probabilité de survenance d'un événement grave, mesurer la perte de valeur marchande qui peut en résulter, puis utiliser ces deux composantes pour construire et tarifer le contrat.

Phase 1 : Préparer les données

Objectif : construire une base permettant de suivre chaque joueur saison après saison.
Les différentes tables du jeu de données doivent être nettoyées puis rapprochées afin de reconstituer, pour chaque joueur et chaque saison, les informations nécessaires à la modélisation.

- Identifier le club et le championnat dans lesquels évolue chaque joueur au cours de la saison, ainsi que son âge, son poste, son temps de jeu, etc.
- Reconstituer son historique de blessures : nombre de blessures, nature de la blessure, durée d'indisponibilité, etc.
- Reconstituer l'évolution de sa valeur marchande au cours du temps, notamment autour des différentes périodes de marché des transferts.

Livrable : une base de données nettoyée et documentée permettant de suivre les caractéristiques, les blessures et l'évolution de la valeur marchande de chaque joueur au fil des saisons.

Phase 2 : Modéliser le risque de blessure grave

Objectif : estimer, pour chaque joueur, la probabilité de subir un événement grave au cours d'une saison.
La première difficulté est de définir ce qui constitue une blessure grave du point de vue de l'assureur. Cette définition pourra combiner plusieurs critères : durée d'indisponibilité, nature de la blessure, séquelles potentielles ou répétition de blessures moins sévères.

- Définir les blessures graves dans le cadre du produit pour pouvoir les différencier des autres blessures.
- Étudier les facteurs expliquant leur survenance : âge, poste, antécédents de blessures, club, championnat, temps de jeu, etc.
- Construire un modèle permettant d'estimer une probabilité de blessure grave pour chaque joueur.
- Ajouter séparément le risque de décès afin d'obtenir la probabilité des événements couverts par le contrat.

Livrable : un modèle permettant d'attribuer à chaque joueur une probabilité annuelle de survenance d'un événement grave.

Phase 3 : Mesurer la perte de valeur marchande

Objectif : quantifier la perte financière associée à la survenance d'une blessure grave.
Une blessure grave n'entraîne pas nécessairement la perte totale de la valeur du joueur. Il faut donc mesurer son impact sur la valeur marchande en comparant son évolution entre deux marchés des transferts, car c'est principalement à ces périodes que les clubs peuvent vendre leurs joueurs et donc matérialiser une éventuelle perte financière.

- Identifier les blessures graves survenues entre deux **marchés des transferts**.
- Calculer la variation relative de **la** valeur du joueur entre ces deux dates.
- Déterminer une règle ou un modèle permettant d'estimer la perte financière associée à une blessure grave.

Livrable : un modèle permettant d'estimer, pour un joueur donné, la perte de valeur marchande associée à la survenance d'une blessure grave.

Phase 4 : Construire et tarifer le produit d'assurance

Objectif : transformer les modèles de fréquence et de perte en un produit d'assurance applicable aux clubs professionnels.
Les deux phases précédentes fournissent les deux éléments nécessaires à la tarification : la probabilité de survenance d'un événement et le montant de la perte qu'il peut entraîner. Il reste à définir la manière dont cette perte est couverte par l'assureur.

- Calculer une prime pure à partir de la fréquence et du coût estimés du risque.
- Tester différentes structures de garantie : franchise, plafond d'indemnisation, pourcentage de perte couvert ou capital maximal assuré.

Livrable : une proposition de produit d'assurance comprenant les garanties, les règles d'indemnisation et une méthode de tarification.

Données utilisées

Un seul jeu de données public disponible sur **Kaggle** suffit. Il regroupe plus de 5,7 millions d'observations sur le football, réparties entre différentes bases pouvant être reliées entre elles grâce aux identifiants des joueurs et des clubs.

- **Profils des joueurs**, avec notamment la date de naissance, la nationalité, le poste, le pied préférentiel et le club actuel.
- **Performances des joueurs**, par saison, compétition et club : temps de jeu, apparitions, buts, passes décisives, cartons, etc.
- **Valeurs marchandes**, avec l'historique des valorisations et leurs dates.
- **Historique des transferts**, avec le club de départ, le club d'arrivée, la date, la valeur du joueur au moment du transfert et le montant du transfert.
- **Historique des blessures**, avec le type de blessure, les dates de début et de fin, le nombre de jours d'indisponibilité et le nombre de matchs manqués.
- **Données sur les clubs et compétitions**, permettant notamment d'identifier le club, le championnat et la saison dans lesquels évolue le joueur.

Résultat attendu

Une chaîne complète et reproductible, de la donnée publique brute issue de Kaggle jusqu'à la construction d'un produit d'assurance de personne clé pouvant être proposé aux clubs de football professionnel.

Mots-clés

Assurance de personne clé, Football professionnel, Blessure, Valeur marchande, Tarification, Perte financière.

Source de données

https://www.kaggle.com/datasets/xfkzujqjvx97n/football-datasets/data

Sujet A2

Modélisation de champs de précipitations pour l'évaluation du risque assurantiel via des modèles génératifs

Mathis Ribordy
ribordy@ceremade.dauphine.fr

2 octobre 2026

Les événements météorologiques extrêmes, et notamment les épisodes de fortes précipitations, constituent une source importante de risque pour les habitations. L'évaluation de ce risque est essentielle pour les assureurs disposant d'un grand portefeuille de biens immobiliers. Considérons un champ de précipitations

$$R(s), \qquad s \in \mathcal{D},$$

où $\mathcal{D}$ désigne une région géographique et $R(s)$ la quantité de précipitations observée au point s. L'objectif de ce projet est d'utiliser un modèle génératif VAE (Kingma and Welling (2022)) afin d'apprendre la loi de tels champs aléatoires et de générer de nouveaux scénarios de précipitations présentant des caractéristiques statistiques similaires aux événements observés. Les données pourront être obtenues à partir de bases météorologiques open source (ex. : COMEPHORE, Météo-France). On cherchera ainsi à apprendre une distribution

$$R(\cdot) \sim P.$$

Une application actuarielle sera ensuite considérée. On pourra introduire un portefeuille immobilier constitué de N biens de valeurs assurées $V_1, \dots, V_N$, localisés en $s_1, \dots, s_N$. Pour un scénario généré R, une fonction de dommage d permettra de définir une perte agrégée

$$L = \sum_{i=1}^{N} V_i \, d(R(s_i)) \, .$$

Les distributions de pertes obtenues à partir des scénarios générés pourront alors être étudiées et comparées, notamment à travers des mesures de risque telles que la Value-at-Risk (VaR) ou l'Expected Shortfall (ES). Les étapes (indicatives) du projet sont les suivantes :

- Comprendre les notions de champs aléatoires et de modélisation des précipitations.
- Constituer le jeu de données, soit à partir des données de Météo-France, soit à partir de données simulées.
- Comprendre les notions de modèles génératifs VAE.
- Implémenter et entraîner un premier modèle génératif. Évaluer les scénarios générés en comparant leurs propriétés statistiques aux données originales.
- Construire un portefeuille immobilier et étudier l'impact des scénarios générés sur la distribution des pertes agrégées.

Références

Kingma, D. P. and Welling, M. (2022). Auto-encoding variational bayes.

Sujet A3

Dauphine | PSL UNIVERSITÉ PARIS

MIDO MATHÉMATIQUES ET INFORMATIQUE DE LA DÉCISION ET DES ORGANISATIONS

Master 1 - Mathématiques et Applications — Année 2026-2027

Mémoire Majeure Actuariat

–

Modélisation de la mortalité journalière et modèles additifs

Encadrant	Quentin Guibert
Structure	Université Paris-Dauphine
Courriel	guibert@ceremade.dauphine.fr
Données	INSEE

Introduction

La modélisation et la projection de la mortalité constituent une préoccupation de premier plan pour les fonds de pension et les États dans la gestion et le pilotage des régimes de retraite. Cette question est également centrale pour la tarification, le provisionnement et la gestion des produits d'assurance vie.

Ce projet s'intéresse à la modélisation de la mortalité journalière et à ses liens avec les variables environnementales. Cette mortalité présente en effet d'importantes fluctuations saisonnières, liées notamment à l'évolution des températures. Un enjeu majeur consiste donc à intégrer l'effet de ces dernières en climat futur, dans un contexte d'intensification des vagues de chaleur en Europe (Guibert et al., 2025).

Contexte et motivations

La relation entre mortalité journalière (ou hebdomadaire) et température est traditionnellement étudiée au moyen d'un modèle non linéaire à retards distribués (DLNM, *distributed lag non-linear model*) (Gasparrini et al., 2010). Ce cadre s'inscrit dans celui des modèles linéaires généralisés et, plus largement, des modèles additifs généralisés (GAM) (Wood, 2006). La série des décès journaliers $(D_t)_{t=1,\dots,n}$ y est régressée sur la trajectoire des températures journalières $(x_t)_{t=1,\dots,n}$ ainsi que sur des covariables $(u_{k,t})_{t=1,\dots,n}$, pour $k = 1, \dots, K$. Conditionnellement aux covariables, on suppose que D_t suit une loi de Poisson, généralement surdispersée (quasi-Poisson) ou binomiale négative. Le modèle s'écrit alors

$$g(\mu_t) = \eta + s(\boldsymbol{q}_t, \boldsymbol{l}; \boldsymbol{\beta}) + \sum_{k=1}^{K} h_k\left(u_{k,t}; \boldsymbol{\gamma}_k\right), \tag{1}$$

où g est la fonction de lien logarithmique, η un coefficient d'intercept, L le retard maximal, s une fonction de *cross-basis* bi-dimensionelle capturant la relation avec les températures, et h_k des fonctions des covariables (généralement des fonctions splines), de paramètres $\boldsymbol{\gamma}_k$. Ces covariables comprennent typiquement une spline du temps, qui capte la tendance de long terme et la saisonnalité résiduelle, des indicatrices du jour de la semaine et des jours fériés, ainsi qu'éventuellement l'humidité, la pollution atmosphérique ou des effets des températures mal capturés par s (canicules prolongées, effet composé sur le jour et la nuit, ...) (Robben et Barigou, 2025 ; Wang et al., 2026). La fonction s s'écrit

$$s(\boldsymbol{q}_t, \boldsymbol{l}; \boldsymbol{\beta}) = \sum_{\ell=0}^{L} f(x_{t-\ell}, \ell) = \sum_{j=1}^{v_x} \sum_{k=1}^{v_\ell} \left(\sum_{\ell=0}^{L} b_j(x_{t-\ell})\, c_k(\ell) \right) \beta_{jk}, \tag{2}$$

avec $\mathbf{q}_t = (x_t, x_{t-1}, \ldots, x_{t-L})^\top \in \mathbb{R}^{L+1}$, et $\boldsymbol{\ell} = (0, 1, \ldots, L)^\top$ un vecteur des ordres de retard. La réponse aux températures en termes de mortalité est capturée par le biais de

$$f(x, \ell) = \sum_{j=1}^{v_x} \sum_{k=1}^{v_\ell} b_j(x)\, c_k(\ell)\, \beta_{jk}, \tag{3}$$

où les fonctions $b_1, \ldots, b_{v_x}$ sont une base de B-splines décrivant la relation non linéaire entre température et risque et $c_1, \ldots, c_{v_\ell}$ sont une base de splines naturelles en échelle logarithmique. De nombreuses variantes de ce cadre ont été développées dans la littérature, e.g. ajout de pénalisation, modélisation spatiale, modélisation bayésienne.

L'utilisation d'un modèle de régression utilisant des splines pose toutefois des contraintes en terme de flexibilité et impose des limites en termes de performances. Ce projet vise à proposer une évolution de ce modèle de regression à partir de modèles additifs plus généraux, mais interpretables comme le modèle Gamboost et GamboostLSS (Mayr et al., 2012), EMB (Krúpová et al., 2026) ou encore NAM (Agarwal et al., 2021 ; Laub et al., 2026).

Objectifs pédagogiques du projet

Ce projet vise à traiter les points suivants :

— Comprendre le fonctionnement du modèle GAM, du modèle DLNM et leur propriétés. Savoir comment les spécifier et les calibrer pour reproduire les tendances de mortalité.
— Apprendre à implémenter ce type de modèle, à le calibrer sur des données journalière et à l'analyser.
— Concevoir un modèle ou plusieurs modèles alternatifs à base de *boosting* comme le modèle EBM, ou de réseaux de neurônes, puis les implémenter.
— Analyser le gain en performance de tels modèles et interpréter les résultats.

Données et applications numériques

Nous souhaitons appliquer ces modèles aux données de mortalité française à une échelle journalière via les données de l'INSEE [1] à partir de 2000. Pour ce projet, les applications numériques seront à réaliser en R.

Pré-requis

En utilisant Planchet et Thérond (2011), documentez-vous sur les principales quantités utilisés dans le cadre de modèle de durée, et qui permettent d'introduire la notions de taux de mortalité.

Attendus du projet

1. Une présentation claire et une compréhension approfondie des modèles présentés.
2. Une proposition de modélisation permettant de faire évoluer le cadre de modèles DLNM.
3. Un code R permettant d'implémenter ces modèles et de reproduire les résultats.

Références

Agarwal, R., Melnick, L., Frosst, N., Zhang, X., Lengerich, B., Caruana, R. et Hinton, G. (2021). Neural Additive Models : Interpretable Machine Learning with Neural Nets. *Advances in neural information processing systems* 34, p. 4699-4711.

1. Les données sont disponibles en libre accès sur le site https://www.insee.fr/fr/information/4190491

Gasparrini, A, Armstrong, B et Kenward, M. G. (2010). Distributed Lag Non-Linear Models. *Statistics in Medicine* 29.21, p. 2224-2234. doi : 10.1002/sim.3940. PMID : 20812303.

Guibert, Q., Pincemin, G. et Planchet, F. (2025). Impacts of Climate Change on Mortality : An Extrapolation of Temperature Effects Based on Time Series Data in France. *International Journal of Forecasting* Accepted. doi : 10.48550/arXiv.2406.02054. arXiv : 2406.02054 [stat].

Krúpová, M., Rachdi, N. et Guibert, Q. (2026). Explainable Boosting Machine for Predicting Claim Severity and Frequency in Car Insurance. *European Actuarial Journal*. doi : 10.1007/s13385-026-00461-y.

Laub, P. J., Pho, T. et Wong, B. (2026). An Interpretable Deep Learning Model for General Insurance Pricing. *Insurance : Mathematics and Economics* 131, p. 103270. doi : 10.1016/j.insmatheco.2026.103270.

Mayr, A., Fenske, N., Hofner, B., Kneib, T. et Schmid, M. (2012). Generalized Additive Models for Location, Scale and Shape for High Dimensional Data—A Flexible Approach Based on Boosting. *Journal of the Royal Statistical Society Series C : Applied Statistics* 61.3, p. 403-427. doi : 10.1111/j.1467-9876.2011.01033.x.

Planchet, F. et Thérond, P.-E. (2011). Modélisation statistique des phénomènes de durée - Applications actuarielles. 2e éd. Assurance Audit Actuariat. Paris : Economica.

Robben, J. et Barigou, K. (2025). A Penalized Distributed Lag Non-Linear Lee-Carter Framework for Regional Weekly Mortality Forecasting. doi : 10.48550/arXiv.2509.24087. arXiv : 2509.24087 [stat]. (Visité le 01/10/2025). Prépubl.

Wang, L., Zhou, R., King, A. et Chen, P. (2026). Evaluating Climate Change Impacts on Mortality, Life Insurance, and Annuities. *Insurance : Mathematics and Economics* 131, p. 103306. doi : 10.1016/j.insmatheco.2026.103306.

Wood, S. N. (2006). Generalized Additive Models : An Introduction with R. 1 edition. Boca Raton, FL : Chapman and Hall/CRC. 410 p.

Sujet A4

Dauphine | PSL UNIVERSITÉ PARIS

MIDO MATHÉMATIQUES ET INFORMATIQUE DE LA DÉCISION ET DES ORGANISATIONS

Master 1 - Mathématiques et Applications — Année 2026-2027

Mémoire Majeure Actuariat

–

Modélisation de la mortalité avec modèles de vitalité

Encadrant	Quentin Guibert
Structure	Université Paris-Dauphine
Courriel	guibert@ceremade.dauphine.fr
Données	HMD

Introduction

La modélisation et la projection de la mortalité est une préoccupation de premier intérêt pour les fonds de pension et les états concernant la gestion et le pilotage de régimes de retraite. Cette question est également importante pour la tarification, le provisionnement et la gestion de produits d'assurance vie.

Récemment, Shimizu et al. (2021) ont introduit une nouvelle classe de modèles destinés à prédire la mortalité humaine, fondée sur le concept d'énergie de survie. Il propose un modèle structurel qui représente de manière intuitive l'énergie vitale d'un individu au moyen d'un processus latent, à l'instar de la manière dont la valeur d'une entreprise est modélisée dans les modèles structurels de risque de crédit, comme le modèle de Merton. L'objectif de ce projet vise à explorer et à concevoir des approches fondées sur ce cadre pour modéliser la mortalité humaine et pour tarifer des contrats d'assurance pour le risque décès.

Contexte et motivations

Le modèle d'énergie de survie (SEM) est gouverné par un processus stochastique dans lequel les individus décèdent lorsque leur énergie atteint zéro. Formellement, le processus est défini de manière générale comme suit

$$\mathrm{d}X_t^c = U(t,\mu_c) + V(t,\sigma_c)\,\mathrm{d}W_t, \quad X_0^c = x_c \in \mathbb{R}_+^\star, \tag{1}$$

où W est un processus de Wiener, $\mu_c \in \mathbb{R}^p$ et $\sigma_c \in \mathbb{R}^q$ représentent respectivement les paramètres de dérive et de volatilité associés à une cohorte donnée c. Le terme x_c correspond à l'énergie initiale à la naissance. Les individus décèdent au temps $\tau_c = \inf\{t > 0,\, X_t^c < 0\}$. Dans un second temps, Shimizu et al. (2023) proposent le modèle Inverse Gaussian SEM (IG-SEM) où l'énergie de survie est un processus inhomogène en temps

$$X_t^c = x_c - Y_t^c,$$

avec Y_t^c un processus inverse gaussien, i.e. $Y_0^c = 0$, Y^c est à accroissements indépendants tels que

$$Y_t^c - Y_s^c \sim IG\left(\Lambda_c(t) - \Lambda_c(s), \sigma_c(\Lambda_c(t) - \Lambda_c(s))^2\right),$$

avec Λ_c une fonction croissante telle que $\Lambda_c(0) = 0$. Un autre cadre proche est introduit par Zhu et al. (2026) en introduisant un processus de vitalité $V(t)$ décrit selon la dynamique

$$V(t) = V(0) - Y(y) - W(t) - J(t), \qquad t \geqslant 0,$$

avec $V(0)$ la vitalité initiale, $Y(t)$ la tendance du processus, $W(t)$ un processus de vieillissement, et $J(t)$ un processus à sauts.

Ces différentes travaux ont été mis en oeuvre et comparer aux modèles stochastiques de mortalité plus classiques. Cependant, l'utilisation des modèles à énergie de survie et de vitalité reste largement inexplorée dans la littérature actuarielle. Dans ce projet, nous cherchons à étudier l'apport des modèles de vitalité pour modéliser la mortalité de la population, et pour tarifer des contrats d'assurance portant sur la mortalité.

Objectifs pédagogique du projet

Ce projet vise à traiter les points suivants :

— Comprendre le fonctionnement des modèles de vitalité et leur propriétés. Savoir comment les spécifier et les calibrer pour reproduire les caractéristiques connues de la mortalité.
— Apprendre à implémenter ce type de modèle et le calibrer sur des données.
— Comprendre le fonctionenement d'une modèle de mortalité classique et comparer les résultats au modèle de vitalité.
— Tarifer un contrats d'assurance portant sur le risque décès.

Données et applications numériques

Nous souhaitons appliquer ces modèles aux données de mortalité française. Sur une échelle annuelle, on pourra s'appuyer sur les données nationales HMD (2026).

Pour ce projet, les applications numériques seront à réaliser en R (R Core Team, 2026). En particulier, on note que le package R **StMoMo** (Millossovich et al., 2018) permet de manipuler de nombreux modèles classiques de mortalité. Il conviendra d'implémenter les modèles de vitalité sous R.

Pré-requis

En utilisant Planchet et Thérond (2011), documentez-vous sur les principales quantités utilisés dans le cadre de modèle de durée, et qui permettent d'introduire la notions de taux de mortalité. En utilisant le support de cours de *Brownian motion and evaluation of contingent claims*, documentez-vous sur les processus de diffusion et notamment le mouvement brownien.

Attendus du projet

1. Une présentation claire des modèles à énergie de survie.
2. Une proposition de modélisation permettant de répliquer fidèlement les dynamiques de taux de décès annuels, puis journaliers.
3. Un code R permettant d'implémenter ces modèles et de reproduire les résultats.

Références

HMD (2026). Human Mortality Database. University of California, Berkeley (USA), and Max Planck Institute for Demographic Research (Germany). Available at www.mortality.org (data downloaded on 2024-01-19).

Millossovich, P., Villegas, A. M. et Kaishev, V. K. (2018). StMoMo : An R Package for Stochastic Mortality Modelling. *Journal of Statistical Software* 84. doi : 10.18637/jss.v084.i03.

Planchet, F. et Thérond, P.-E. (2011). Modélisation statistique des phénomènes de durée - Applications actuarielles. 2e éd. Assurance Audit Actuariat. Paris : Economica.

R Core Team (2026). R : A Language and Environment for Statistical Computing. R Foundation for Statistical Computing. Vienna, Austria.

Shimizu, Y., Minami, Y. et Ito, R. (2021). Why Does a Human Die ? A Structural Approach to Cohort-Wise Mortality Prediction under Survival Energy Hypothesis. *ASTIN Bulletin : The Journal of the IAA*, p. 1-29. doi : 10.1017/asb.2020.32.

Shimizu, Y., Shirai, K., Kojima, Y., Mitsuda, D. et Inoue, M. (2023). Survival Energy Models for Mortality Prediction and Future Prospects. *ASTIN Bulletin : The Journal of the IAA* 53.2, p. 377-391. doi : 10.1017/asb.2023.10.

Zhu, X., Zhou, K. Q. et Wang, Z. (2026). Mortality Modeling via Vitality : Model Constructions and Actuarial Applications. *Insurance : Mathematics and Economics* 126, p. 103181. doi : 10.1016/j.insmatheco.2025.103181.

Sujet A5

Université Paris Dauphine – PSL MIDO

Master 1 – Mathématiques et Applications Année 2026–2027

Mémoire Majeure Actuariat

–

Prévision de la mortalité en Europe :
Lee–Carter, Li–Lee et modèles de fondation

Auteur et encadrant	Tachfine EL ALAMI
Formation	Master 1 – Majeure Actuariat
Données	Human Mortality Database (HMD)
Populations	France, Angleterre et pays de Galles, Suède, Danemark, Pays-Bas et Italie

Contexte et objectif du projet

L'évolution de la mortalité occupe une place centrale dans les travaux des actuaires. Elle détermine notamment la durée de versement des rentes et intervient dans la tarification des contrats d'assurance vie ainsi que dans l'évaluation des engagements des régimes de retraite. Pour anticiper cette évolution, les modèles stochastiques de mortalité décrivent les effets de l'âge et du temps à partir des observations passées. Le modèle de Lee et Carter (1992) constitue une référence largement utilisée dans ce cadre.

Lorsque plusieurs populations présentent des évolutions proches, leur étude conjointe permet de tenir compte de tendances communes tout en conservant leurs spécificités. Cette approche peut enrichir les prévisions obtenues pour chaque population et limiter les divergences à long terme auxquelles peut conduire une modélisation séparée. Le modèle de Li et Lee (2005) prolonge ainsi celui de Lee–Carter en introduisant une composante commune à un ensemble de populations.

Parallèlement à ces approches, les modèles de fondation ouvrent de nouvelles perspectives pour la prévision des séries temporelles. Leur pré-entraînement sur de nombreuses séries permet de les appliquer à de nouvelles données sans ajuster leurs paramètres, selon une utilisation dite zero-shot. Chronos-2 peut notamment exploiter plusieurs séries liées au sein d'une même prévision (Ansari et al., 2025). Son application à la mortalité offre donc un cadre pour comparer le partage d'information entre populations dans un modèle de fondation et dans un modèle actuariel.

L'objectif de ce projet est de comparer ces approches sur six populations européennes : la France, l'Angleterre et le pays de Galles, la Suède, le Danemark, les Pays-Bas et l'Italie. Ces populations disposent de séries longues dans la Human Mortality Database et sont étudiées dans la littérature sur la mortalité multipopulation (Li et Lee, 2005; Hatzopoulos et Haberman, 2013). L'Angleterre et le pays de Galles seront considérés comme une seule population.

L'étude portera d'abord sur Lee–Carter, estimé séparément pour chaque population, puis sur Li–Lee, estimé conjointement pour les six populations. Ces résultats seront comparés à ceux de Chronos-2 en univarié et en multivarié, dans les deux cas en zero-shot. La comparaison permettra d'évaluer l'apport de l'information commune à la précision des prévisions et à leur cohérence démographique. Si le temps le permet, elle sera complétée par une adaptation de Chronos-2 aux données de mortalité par fine-tuning.

Guide pour le démarrage du projet

Pour démarrer ce projet, les étapes suivantes vous sont proposées :

1. En vous appuyant sur Planchet et Thérond (2011), rappeler les principales notions des modèles de durée. Introduire les probabilités de survie, les taux de mortalité et l'espérance de vie.

2. Télécharger et explorer les données HMD des six populations. Retenir une période et une plage d'âges communes. Examiner les décès, les expositions et les taux de mortalité, séparément pour les femmes et les hommes.

3. Présenter le modèle de Lee et Carter (1992) et l'estimer pour chaque population. Projeter les taux de mortalité et commenter les résultats.

4. Présenter le modèle de Li et Lee (2005) et l'estimer sur les six populations. Analyser la tendance commune et les composantes propres à chaque population.

5. Appliquer Chronos-2 en zero-shot aux logarithmes des taux. En univarié, traiter chaque série pays–âge–sexe séparément. En multivarié, regrouper les six populations à âge et sexe fixés. Utiliser le même modèle pré-entraîné dans les deux cas (Équipe Chronos, 2026).

6. Comparer les prévisions sur les mêmes périodes de test, à plusieurs dates et horizons. Utiliser uniquement les données antérieures à chaque date de prévision. Examiner les erreurs et la cohérence des trajectoires entre populations.

7. Si le temps le permet, réaliser un fine-tuning de Chronos-2 en univarié et en multivarié. Réserver les périodes de test à l'évaluation. Mesurer le gain par rapport au zero-shot.

8. Présenter les principaux résultats et discuter les limites des modèles. Fournir les scripts et les réglages nécessaires pour reproduire l'étude localement.

Références

Ansari, A. F., Shchur, O., Küken, J. et al. (2025). Chronos-2 : From Univariate to Universal Forecasting. arXiv:2510.15821.

Équipe Chronos (2026). Chronos : Pretrained Models for Time Series Forecasting. Code, modèles et documentation officielle ; consultation le 4 octobre 2026. https://github.com/amazon-science/chronos-forecasting.

Hatzopoulos, P. et Haberman, S. (2013). Common mortality modeling and coherent forecasts. An empirical analysis of worldwide mortality data. Insurance : Mathematics and Economics, 52(2), 320–337. doi:10.1016/j.insmatheco.2012.12.009.

Human Mortality Database (2026). Données de mortalité et documentation méthodologique. https://www.mortality.org/. La disponibilité des séries doit être vérifiée à la date d'extraction : https://www.mortality.org/Data/DataAvailability.

Lee, R. D. et Carter, L. R. (1992). Modeling and Forecasting U.S. Mortality. Journal of the American Statistical Association, 87(419), 659–671. doi:10.2307/2290201.

Li, N. et Lee, R. (2005). Coherent mortality forecasts for a group of populations : An extension of the Lee–Carter method. Demography, 42(3), 575–594. doi:10.1353/dem.2005.0021.

Planchet, F. et Thérond, P.-E. (2011). Modélisation statistique des phénomènes de durée : applications actuarielles. Economica.

Planchet, F., Thérond, P.-E. et Juillard, M. (2011). Modèles financiers en assurance : analyses de risque dynamiques. 2e édition, Economica.

Sujet A6

Université Paris Dauphine – PSL MIDO

Master 1 – Mathématiques et Applications Année 2026–2027

Mémoire Majeure Actuariat

–

Prévision des séries financières :
ARIMA, XGBoost et modèles hybrides

Auteur et encadrant	Tachfine EL ALAMI
Formation	Master 1 – Majeure Actuariat
Données	Séries américaines issues de FRED
Variables	Inflation, chômage, taux d'intérêt, actions et spread de crédit

Contexte et objectif du projet

L'évolution des taux d'intérêt, des prix des actifs et de l'inflation intervient dans de nombreux problèmes financiers et actuariels. Elle influence la valeur des portefeuilles, le coût des engagements et les décisions de gestion actif-passif. La modélisation de ces variables constitue ainsi une étape importante dans la construction de scénarios économiques utilisés en assurance (Ahlgrim et al., 2008). Leur prévision reste cependant délicate, en raison des changements de régime, des crises et de la variabilité des relations observées au cours du temps.

Les modèles classiques de séries temporelles décrivent la dynamique d'une variable à partir de son passé. Les modèles ARIMA représentent les dépendances linéaires après une éventuelle différenciation. Les modèles ARCH et GARCH permettent, quant à eux, de décrire les variations de la volatilité conditionnelle, fréquentes dans les rendements financiers. Ces approches fournissent un cadre de référence pour l'analyse et la prévision (Hyndman et Athanasopoulos, 2021; Tsay, 2010).

Les méthodes d'apprentissage automatique offrent d'autres possibilités pour exploiter l'information historique. Les arbres de décision et les méthodes de boosting, notamment XGBoost (Chen et Guestrin, 2016), peuvent apprendre des relations non linéaires entre une variable et ses valeurs retardées. Leur souplesse doit toutefois être confrontée à la taille des échantillons et au risque de surapprentissage. Une autre approche consiste à associer un modèle de séries temporelles à un modèle d'apprentissage chargé de corriger ses erreurs, dans l'esprit des méthodes hybrides étudiées par Zhang (2003).

Les données économiques diffusées par FRED offrent un cadre commun pour étudier ces différentes approches. Leur utilisation en prévision actuarielle est notamment illustrée par Zhu et al. (2025), qui mobilisent un grand nombre de variables pour prévoir plusieurs indicateurs économiques. Le présent projet retient un cadre plus restreint, adapté à une comparaison progressive des méthodes.

L'objectif est de mesurer l'apport de l'apprentissage automatique à la prévision de séries financières et macroéconomiques américaines. Pour chaque série, l'étude comparera un modèle ARIMA, un modèle XGBoost utilisé seul et une combinaison ARIMA–XGBoost. La comparaison portera d'abord sur des prévisions univariées, construites à partir du seul passé de la variable étudiée. Elle pourra ensuite être enrichie par d'autres méthodes d'apprentissage ou par l'ajout de variables explicatives. Les résultats seront évalués hors échantillon, selon les séries et les horizons, sans présumer de la supériorité d'une famille de modèles.

Guide pour le démarrage du projet

Pour démarrer ce projet, les étapes suivantes vous sont proposées :

1. En vous appuyant sur Hyndman et Athanasopoulos (2021) et Tsay (2010), rappeler les notions de stationnarité, de bruit blanc, d'autocorrélation et de prévision conditionnelle. Présenter les modèles AR, MA, ARMA et ARIMA. Distinguer la prévision de la moyenne de celle de la volatilité.

2. Télécharger depuis FRED les séries suivantes : prix à la consommation (`CPIAUCSL`), chômage (`UNRATE`), taux du Trésor à trois mois (`TB3MS`) et à dix ans (`GS10`), indice Nasdaq Composite (`NASDAQCOM`) et spread Baa–Treasury dix ans (`BAA10YM`). Utiliser l'export CSV ou l'API. Documenter les producteurs, les unités et la date d'extraction. Retenir une période mensuelle commune, par exemple 1972–2025.

3. Calculer l'inflation mensuelle par $100 \log(CPI_t/CPI_{t-1})$. Pour les actions, retenir la dernière clôture disponible de chaque mois et calculer $R_t = 100 \log(P_t/P_{t-1})$, hors dividendes. Conserver initialement les taux et le spread dans leurs unités d'origine. Examiner les valeurs manquantes, les distributions, les ruptures et les autocorrélations. Justifier les différenciations éventuelles et vérifier la stationnarité.

4. Définir un découpage chronologique commun : par exemple, apprentissage jusqu'en 2004, validation sur 2005–2014 et test sur 2015–2025. Évaluer les horizons de 1, 3 et 12 mois à origines successives, sur les mêmes dates pour tous les modèles. Choisir les réglages sur la validation, puis les figer. À chaque origine, réestimer uniquement sur le passé disponible. Ne pas mélanger aléatoirement les observations.

5. Estimer un ARIMA pour chaque série. Justifier les ordres retenus et examiner les résidus. Comparer ses prévisions à une référence simple : dernière valeur observée pour les niveaux, rendement nul pour les actions. Une composante saisonnière pourra être introduite si nécessaire.

6. Présenter XGBoost et construire un problème de régression à partir des retards de chaque série (Chen et Guestrin, 2016). Choisir le nombre de retards, la profondeur des arbres et la régularisation par validation chronologique. Pour chaque horizon h, prévoir directement y_{t+h} à partir d'informations datées au plus tard de t.

7. Construire une combinaison ARIMA–XGBoost en apprenant à corriger les erreurs d'ARIMA. Pour chaque horizon, produire les erreurs d'apprentissage par prévisions successives dans le passé, avec un ARIMA estimé uniquement avant chaque origine. Ajuster XGBoost sur ces erreurs et sur les retards disponibles à cette origine. Additionner ensuite la prévision ARIMA et la correction prédite, sur la même échelle. Les erreurs du test ne doivent pas servir à régler la combinaison.

8. Comparer ARIMA, XGBoost et le modèle hybride à l'aide de la MAE et de la RMSE, par série et par horizon. Revenir à l'échelle de la variable cible après différenciation. Examiner séparément les périodes de crise et la stabilité des gains. Discuter les limites dues aux révisions des données FRED et aux délais de publication : l'étude sur données révisées ne reproduit pas exactement une prévision en temps réel.

9. Si le temps le permet, comparer une forêt aléatoire ou un réseau de neurones, puis ajouter les retards d'autres variables au modèle ML. Étudier éventuellement l'immobilier (`HPIPONM226S`) ou le VIX (`VIXCLS`), sur une période adaptée. Un modèle GARCH pourra compléter l'étude de la volatilité des rendements. Présenter une synthèse et fournir les scripts et réglages nécessaires à la reproduction des résultats.

Références

Ahlgrim, K. C., D'Arcy, S. P. et Gorvett, R. W. (2008). A Comparison of Actuarial Financial Scenario Generators. Variance, 2(1), 111–134. Article disponible sur le site de la Casualty Actuarial Society.

Chen, T. et Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. doi:10.1145/2939672.2939785. Version libre : arXiv:1603.02754.

Federal Reserve Bank of St. Louis (2026). FRED : Federal Reserve Economic Data. Séries et documentation ; consultation le 4 octobre 2026. https://fred.stlouisfed.org/. Les identifiants du guide donnent accès aux fiches des séries. Citer également leur producteur d'origine.

Hyndman, R. J. et Athanasopoulos, G. (2021). Forecasting : Principles and Practice. 3e édition, OTexts. Ouvrage accessible en ligne : https://otexts.com/fpp3/.

Tsay, R. S. (2010). Analysis of Financial Time Series. 3e édition, Wiley. doi:10.1002/9780470644560.

Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. Neurocomputing, 50, 159–175. doi:10.1016/S0925-2312(01)00702-0. Cet article porte sur une combinaison avec un réseau de neurones ; il motive le principe d'hybridation, adapté ici à XGBoost.

Zhu, F., Dong, Y. et Huang, F. (2025). Data-rich Economic Forecasting for Actuarial Applications. Insurance : Mathematics and Economics, 124, 103126. doi:10.1016/j.insmatheco.2025.103126. Prépublication disponible sur SSRN.

Précisions sur les données

Le Nasdaq Composite est retenu pour disposer d'un historique long sur FRED. Il représente un univers d'actions différent du S&P 500. La série `SP500` peut être étudiée en complément, mais son historique diffusé par FRED est limité à dix ans à la date de rédaction, ce qui réduit fortement la taille d'un échantillon mensuel.

L'immobilier et le VIX constituent des prolongements facultatifs ; leur ajout ne doit pas raccourcir l'historique de l'étude principale. La comparaison avec des variables explicatives devra être distinguée de la comparaison univariée afin de séparer l'effet du modèle de celui de l'information supplémentaire.